engenharia de prompt em português brasileiro

prompt

preciso

apresentação ao time de engenharia de software · nov 2026

github.com/saulofilho/prompt-engineering-ptbr

resumo executivo

o essencial em três frases

01

português preciso é legítimo

claro e acessível ao time lusófono. não exige pensar em inglês para dar certo.

02

o custo de token é real, mas medido

português paralelo custa +12,8% a +29% em tokens frente ao inglês. decidimos com dado, não folclore.

03

o retorno é precisão e padronização

menos ambiguidade, menos retrabalho e um plugin de skills para o time escrever igual.

o problema

três atalhos que o time repete sem medir

~~"escreve em inglês que gasta menos token"~~

inglês custa menos, sim — mas troca acesso e clareza por um ganho que dá para medir e decidir.

~~"usa ABNT que comprime o pedido"~~

a ABNT regula citação e numeração. não é técnica de token nem estilo de prompt.

a tese

português pode ser claro, acessível e exato. o custo em tokens existe e depende do vocabulário.

ele não se resolve com a sigla ABNT, tirando acento, nem obrigando a pensar em inglês. resolve-se com instrução menos ambígua e medição do fluxo inteiro: entrada, saída e retrabalho.

o que construímos

um laboratório, um plugin e um site aberto

laboratório

hipóteses pré-registradas, 12 tarefas pareadas PT × inglês e scripts que contam tokens e versionam o resultado.

plugin de skills

cinco skills para o agente escrever, conferir e medir o pedido. instala com /add-plugin prompt-ptbr.

site + docs

github pages com leitor dos documentos do repositório. tudo aberto: código MIT, texto CC BY 4.0.

método

medição que resiste a viés

01 braços pareados

a mesma tarefa em inglês, paralelo, otimizado, coloquial, vago e sem acento.

02 hipóteses pré-registradas

H1 a H8, com limiar e escopo fixados antes de contar o token.

03 tarefas de software real

resumo de chamado, extração de cobrança, validar

04 não inventa número

tokenizador publicado do modelo; sem resposta da API,

desafios

o que ainda é difícil — e assumimos

tokenizadores fechados

Claude, Gemini e Sabiá não publicam o vocabulário. não dá para contar token sem a API.

a penalidade varia

o custo PT/EN depende do tokenizador: 1,13× no o200k, 1,29× no cl100k. não é um número só.

falsa otimização

encurtar apagando critério engana: o braço vago gasta 85%

qualidade ainda não medida

sem chave de API no piloto, resposta e reprompt ficam fora, a

resultado · a penalidade

português custa mais — e dá para dizer quanto

+12,8%

fonte: poc_v0_tokenizacao.md · soma das 12 tarefas · prompt completo

tokenizador	inglês	pt paralelo	razão
GPT-4o · o200k_base	896	1011	1,128×
GPT-4 / 3.5 · cl100k_base	905	1168	1,291×

resultado · otimizar de verdade

cortar ambiguidade, não cortar critério

−22,9%

otimizado vs coloquial

economia real de tokens na instrução, mantendo todos os critérios. isto é

−85,2%

vago vs otimizado

gasta muito menos, mas apaga critério. barato e inútil — a falsa

+2,5%

sem acento vs otimizado

tirar diacrítico custou mais tokens e piorou a leitura. o atalho que não

fonte: poc_v0_tokenizacao.md · escopo instrução, o200k_base

resultado · forma controlada (h6)

clareza estruturada custa quase nada

+5,5%

escopo	otimizado	controlado	dif.
instrução	487	514	+5,5%
completo	1020	1035	+1,5%

fonte: poc_v1_controlado.md · o200k_base · limiar de recusa de H6: ≥15%

uma ideia por frase, no máximo 20

resultado · custo em dólar

a penalidade, em dinheiro, é pequena

≈ US$ 24

a mais por **milhão de prompts** de entrada (GPT-4o), pela aritmética do mesmo número medido. não inclui saída nem reprompt.

entrada · 12 prompts	inglês	pt-br
GPT-4o (USD)	0,002240	0,002527

Claude, Gemini e Sabiá ficam **sem dólar**: o tokenizador deles não é público. preço honesto só onde há token medido.

fonte: custo_usd.md · preços de 22 out 2026 · só entrada

o produto · plugin de skills

cinco skills que o time usa no agente

`using-prompt-ptbr`	escolhe a skill certa e lista o que o agente não pode afirmar.
`writing-precise-ptbr`	imperativo, regras conferíveis, termo estável e frase de ausência.
`checking-prompt`	marca o checklist e recusa chamar de otimizada a versão só curta.
`scoping-abnt`	citação e numeração onde a norma regula — não como truque de token.

retorno para o time

o ganho não é token — é retrabalho

menos retrabalho

instrução precisa corta 22,9% da ambiguidade sem perder critério. menos reprompt, menos saída errada para corrigir.

custo conhecido

decidir idioma com número: +12,8% de token no modelo atual. e parar de pagar por atalhos que não funcionam.

padronização

cinco skills dão um jeito único de escrever e revisar prompt. prompts auditáveis e onboarding mais rápido.

honestidade: isto não é ferramenta de corte de custo — o português custa um pouco mais. é disciplina de precisão, com o custo medido.

próximos passos

o que falta medir

qualidade com api

rodar com chave real: nota automática, alucinação, reprompt e o dólar do fluxo inteiro.

avaliação humana (h8)

omissão de critério por quem escreve, com participante, consentimento e avaliador cego.

formato da saída (h7)

frases, Mermaid e HTML: medir o custo do formato pedido na resposta.

modelos fechados

razão PT/EN de Claude, Gemini e Sabiá só com o usage que a API devolver.

como adotar

precisão em português, medida e padronizada

01 instale o plugin e use as skills nas tarefas reais do time.

02 meça o custo no tokenizador do modelo que vocês usam, antes de decidir.

03 traga uma tarefa de vocês para virar hipótese e entrar no benchmark.

saulofilho.github.io/prompt-engineering-ptbr

/add-plugin prompt-ptbr